Extended MongoDB for Machine Learning: Data (Exploration) Analysis, Data Processing and Model Training

Group 9

林天行 黃千睿 黃品翰 王睿謙 王雅茵

Outline

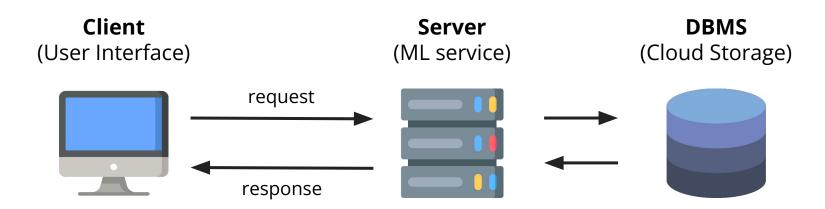
- Problem
- Solution
- Implementation
- Tools
- Objectives & Results (Phase I , Phase II)
- Limitation
- Possible extensions

Problem

- 機器學習(ML)的需求日益增長, 處理龐大的資料集經常是使用者會面對的挑戰
- 一般使用情境:
 - 1. 先將遠端的訓練資料下載到本地端
 - 2. 於本地端進行資料探索→ 資料前處理 → 訓練模型
- Challenges:
 - 1. 資料量太過龐大導致耗時、佔用電腦資源&儲存空間:升級硬體規格才能改善
 - 2. 環境架設難度高:ERROR一堆, 處處不相容, 總之套件就是裝不上去==
 - ⇒困難重重

Solution

Architecture design:
 使用者先傳送請求到遠端server,並透過遠端server連結雲端DB的資料來運行ML,再傳輸結果至client端。



Solution

● 優點:

- 1. **遠端運行、本地接收**:將機器學習模型部署在遠端:erver,使用雲端或專門的計算資源來處理資料集和訓練模型,client端只需要下指令與接收結果。
 - → 大幅節省本地資源的使用, 並享受遠端服務提供的高效率計算能力。
- 2. **資料前處理**:提供基本的前處理功能(scaling, duplicates, missing value, etc.)
 - → 由server負責與雲端DB互動,不需自行撰寫函數或上傳下載資料。
- 3. **使用者介面**:使用者可直接選擇資料前處理方式、模型、資料視覺化的方式。
 - → 降低使用門檻, 增進人機互動的使用者體驗。

Implementation

- 整合兩種介面:
 - Original MongoDB operations
 - Extended MongoDB for data exploration & preprocessing and model training
- 提供之功能
 - Original MongoDB operations
 - Data Exploration & Analysis (e.g. feature box plot)
 - Data Preprocessing: Various re-scaling, imputing, remove outliers strategies
 - Model Selection & Model Training
 - Analyze prediction results (e.g. Heatmap...)

Implementation (Extended MongoDB)

response

Client (User Interface) Request





DBMS (Cloud Storage)

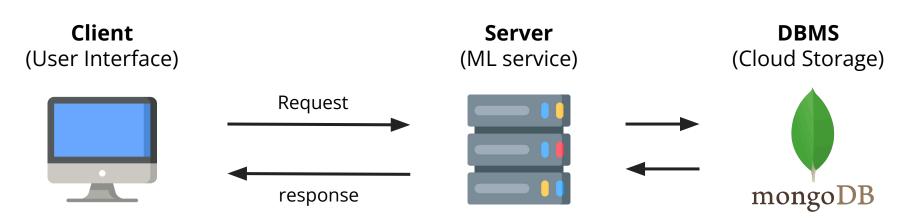


1. Store dataset

- 1. Connect to server
- 2. Send Requests
 - a. Specify db
 - b. Explore Data
 - c. Specify collections to train/test
 - d. Specify feature/label columns
 - e. Select preprocessing method
 - f. Select ML model

- 1. Parse requests
- 2. Connect to & load data from MongoDB
- 3. Handle data exploration & preprocessing request
- 4. Run model
- 5. Send results & plots to client

Implementation (Original MongoDB)



- 1. Connect to server
- 2. Send Requests
 - a. Specify db
- b. Input mongodb-syntaxed operations

- 1. Parse requests and save in a .js file
- 2. Connect to Mongosh
- 3. Mongosh read .js file as input
- 4. Receive results from Mongosh
- 5. Postprocess and send to client

1. Store dataset

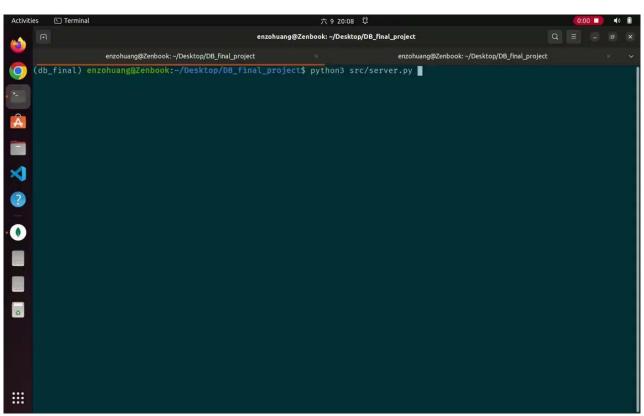
Tools

- 使用之第三方套件、框架、程式碼
 - Programming: Python
 - Client: UI (not implemented yet)
 - Server: pymongo, socket...
 - Data preprocessing: sklearn, pandas, numpy
 - Data Exploration: seaborn, missingno, matplotlib
 - o DBMS: MongoDB
- Data preprocessing functions:
 - Scaling, Removing duplicates, Handling missing value
- Data exploration functions:
 - Missing value indicator, numeric distribution

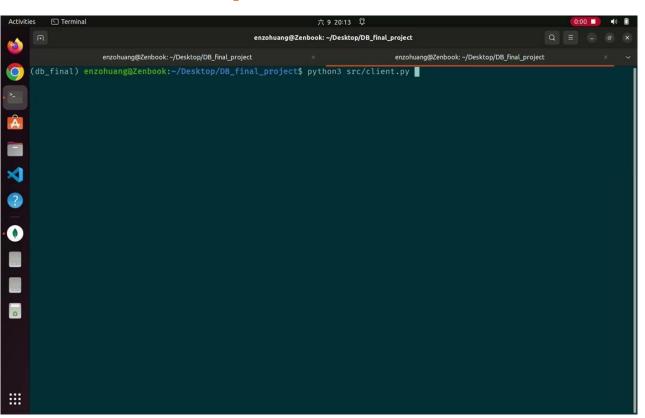
Phase I Objectives

- 確定可以使用 PyMongo & other packages 完成對數據的分析和處理
- Data Exploration → Data Preprocessing → Model selection
 - → Model Training & Prediction流程
- 使用 socket 實現 Client-Server 傳輸
- 支援原本的 MongoDB 操作

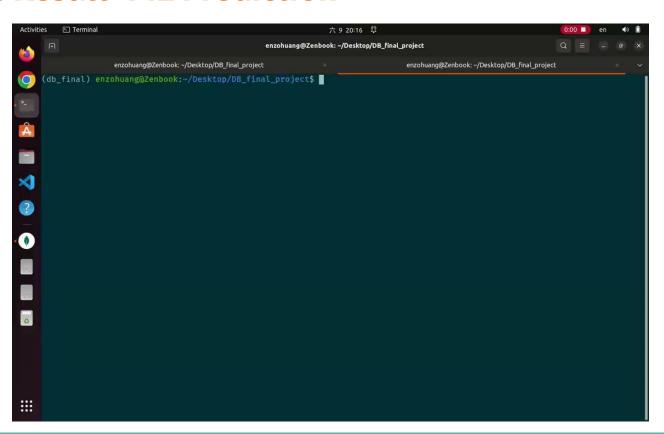
Phase I Result-Data exploration 1



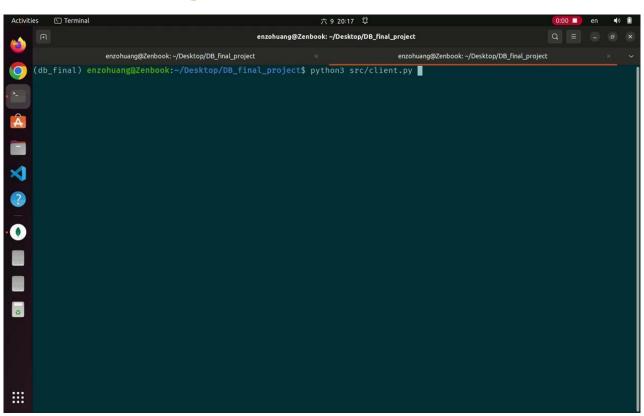
Phase I Result-Data exploration 2



Phase I Result-ML Prediction



Phase I Result-MongoDB operation



Phase II Objectives

- 1. 製作前端介面
 - 1.1. 提供 editor 讓使用者輸入 MongoDB 的指令
 - 1.2. 提供資料前處理、ML模型種類的選單. 取代CMD操作
 - 1.3. 讓使用者可以更輕易的操作, 有更好的使用體驗
- 2. 增加更多的資料探索、資料前處理、訓練模型的種類

Limitation

- 1. 不夠客製化: 目前的 data 相關的 method 或是 model 都是 pre-defined 的, 使用者無法選擇沒有提供的 model 或是 method
- 2. 缺少身份驗證的機制 (e.g. 誰可以連到 mongoDB)
- 3. 無法偵測惡意的 MongoDB operation: 使用者可能會試圖執行惡意或不符合權 限的指令(如:刪掉 db 裡面的所有資料). 但是 server 目前沒有檢查的機制

Possible Extension

- 1. 增加更多的資料前處理、訓練模型的種類
- 提供使用者能夠 extend 功能的格式化介面, 能夠輕鬆擴展並客製化自己常用的
 Data methods 和 models
- 3. 權限控制: server 要可以辨別該使用者可以執行哪些操作

THANK YOU

Demo Video Link

Video link: https://youtu.be/31xuflYUrtU

Github link: https://github.com/a113062130630210/DB final project